

Projet TDN - Analyse des cereales

Binome 5

2025-2026

1 Introduction

Ce rapport presente l'analyse d'un jeu de donnees portant sur 77 cereales de petit-dejeuner commercialisees aux Etats-Unis. L'objectif est de comprendre comment ces cereales se differentient sur le plan nutritionnel, et si on peut identifier des groupes homogenes parmi elles.

On dispose de 16 variables par cereale : des informations nutritionnelles (calories, proteines, graisses, etc.), des variables de conditionnement (poids, taille de portion), et des metadonnees (fabricant, type de consommation, note de satisfaction). Les variables sont mesurees dans des unites tres differentes (Kcal, grammes, milligrammes, note sur 100), ce qui oriente directement le choix des methodes.

L'approche retenue combine une ACP normee pour reduire la dimensionnalite et visualiser les relations entre variables, suivie de deux methodes de classification (CAH et K-means) pour regrouper les cereales en profils nutritionnels distincts.

2 Description des donnees

2.1 Presentation du jeu de donnees

Le fichier `276-cereals.txt` contient 77 cereales decrites par 16 variables. Apres examen de la structure, on distingue trois types de variables :

- **Identifiant** : NAME (nom de la cereale)
- **Variables qualitatives** : MANUF (fabricant, 7 modalites : A, G, K, N, P, Q, R) et TYPE (C = consommation froide, H = chaude)
- **Variables quantitatives** (13) : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS, VITAMINS, SHELF, WEIGHT, CUPS, RATING

La repartition est desequilibree : 74 cereales froides contre seulement 3 chaudes. Les fabricants Kellogg's (K, 23 cereales) et General Mills (G, 22) dominent le jeu de donnees.

2.2 Pretraitement

Certaines valeurs sont codees -1 dans le fichier original. Apres verification, il s'agit de donnees manquantes (une valeur negative n'a pas de sens pour des contenus nutritionnels). On a identifie 4 valeurs manquantes : 2 pour POTASS, 1 pour CARBO, 1 pour SUGARS.

On a choisi de les imputer par la mediane de chaque variable. La mediane est plus robuste que la moyenne face aux valeurs extremes, ce qui est pertinent ici puisque certaines variables comme FIBER ou POTASS presentent des distributions tres asymetriques.

2.3 Definition des roles pour l'ACP

Pour l'ACP, on a selectionne 9 variables actives correspondant aux caracteristiques nutritionnelles pures : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS et VITAMINS.

Les variables SHELF, WEIGHT, CUPS et RATING sont traitees comme variables supplementaires quantitatives : elles ne participent pas a la construction des axes mais sont projetees a posteriori pour enrichir l'interpretation. MANUF et TYPE sont des variables supplementaires qualitatives.

Ce choix se justifie : WEIGHT et CUPS decrivent le conditionnement, pas la composition nutritionnelle. RATING est une note calculee par Consumer Reports, donc une variable derivee qu'on prefere analyser en supplementaire pour voir comment elle se positionne par rapport aux axes nutritionnels.

3 Statistiques descriptives

3.1 Analyse univariee

Le tableau ci-dessous resume les principales statistiques des variables actives :

TABLE 1: Statistiques des variables actives

	Moyenne	Mediane	Ecart.type	Skewness
CALORIES	106.9	110.0	19.5	-0.44
PROTEIN	2.5	3.0	1.1	0.73
FAT	1.0	1.0	1.0	1.14
SODIUM	159.7	180.0	83.8	-0.56
FIBER	2.2	2.0	2.4	2.38
CARBO	14.8	14.5	3.9	0.11
SUGARS	7.0	7.0	4.3	0.04
POTASS	98.4	90.0	69.5	1.40
VITAMINS	28.2	25.0	22.3	2.42

Quelques constats : FIBER (skewness = 2.38) et VITAMINS (2.42) sont tres asymetriques a droite, ce qui signifie que la plupart des cereales ont peu de fibres et de vitamines, avec quelques exceptions notables. SUGARS est a peu pres symetrique (skewness = 0.04), les cereales se repartissent assez uniformement entre peu et tres surees.




FIGURE 1 – Boxplots des variables actives (centrees-reduites)

Les boxplots montrent plusieurs outliers, en particulier pour FIBER et POTASS (les cereales All-Bran) et pour VITAMINS (les cereales “Total” enrichies a 100% des apports). On conserve ces observations car elles representent de vraies cereales du marche, meme si elles sont atypiques.

3.2 Analyse bivariée




FIGURE 2 – Matrice de corrélation des variables actives

La matrice de corrélation révèle une structure intéressante. La corrélation la plus forte est entre FIBER et POTASS ($r = 0.91$). Ce lien est logique d'un point de vue nutritionnel : les céréales complètes riches en fibres conservent les minéraux du grain, dont le potassium. On note aussi que CALORIES est corrélée positivement à SUGARS ($r = 0.57$) et FAT ($r = 0.50$), ce qui reflète simplement le fait que sucres et graisses sont des sources caloriques.

CARBO est corrélée négativement à SUGARS ($r = -0.47$), ce qui peut sembler contre-intuitif. En fait, les céréales riches en glucides complexes (amidon) sont souvent moins sucrées : les sucres simples remplacent l'amidon, pas s'y ajoutent.

L'existence de ces corrélations justifie le recours à l'ACP : les 9 variables ne sont pas indépendantes, et une réduction de dimension permettra de mieux visualiser cette structure.

4 Analyse en composantes principales

4.1 Choix de l'ACP normée

Les variables étant mesurées dans des unités différentes (Kcal, grammes, milligrammes, note), une ACP non normée donnerait un poids disproportionné aux variables à forte variance comme SODIUM (écart-type =

84) ou POTASS (ecart-type = 69) par rapport a FAT (ecart-type = 1). L'ACP normee, qui travaille sur la matrice de correlation apres centrage-reduction, traite toutes les variables de maniere equitable.

4.2 Valeurs propres et nombre d'axes




FIGURE 3 – Eboulis des valeurs propres

Le critere de Kaiser (valeurs propres > 1) conduit a retenir 4 axes, qui captent 82.1% de l'inertie totale. Les deux premiers axes concentrent a eux seuls 52.4% de l'information, ce qui est correct pour 9 variables. Le scree plot ne montre pas de coude tres marque, mais une decroissance progressive. On se concentrera sur le plan factoriel (1,2) pour les interpretations principales, en gardant a l'esprit que les axes 3 et 4 portent encore de l'information non negligeable.

4.3 Cercle des correlations




FIGURE 4 – Cercle des correlations (axes 1-2)

L'axe 1 (29.4% d'inertie) est principalement construit par FIBER et POTASS du cote positif. C'est un axe qu'on peut interpreter comme un gradient de "richesse en fibres". Les cereales a droite du plan sont riches en fibres et en potassium, celles a gauche en sont pauvres.

L'axe 2 (23.0%) oppose CALORIES, FAT et SUGARS (en haut) a un pole plus neutre (en bas). C'est un axe de "densite calorique" : les cereales en haut du plan sont plus caloriques, plus grasses et plus surees.

On remarque que SODIUM et VITAMINS sont mal representes sur ce plan (vecteurs courts), ce qui confirme que les axes 3 et 4 capturent l'information de ces variables. CARBO est dans le cadran bas-gauche, oppose a SUGARS : cela confirme l'opposition glucides complexes / sucres simples vue dans les correlations.

4.4 Carte des individus et biplot




FIGURE 5 – Biplot - individus et variables

Le biplot permet de voir les cereales et les variables en meme temps. Les trois cereales All-Bran (100% Bran, All-Bran, All-Bran with Extra Fiber) sont clairement isolees a droite, du cote des fibres. A l'oppose, on trouve Rice Chex, Corn Chex et d'autres cereales a base de riz ou mais, pauvres en fibres.

En haut du plan, les cereales surees (Cap'n Crunch, Froot Loops, Lucky Charms) s'alignent avec les vecteurs SUGARS et CALORIES. En bas, les cereales peu caloriques comme Puffed Rice ou Shredded Wheat.

4.5 Variables supplementaires

La variable RATING se projette avec une coordonnee positive sur l'axe 1 (+0.62) et negative sur l'axe 2 (-0.72). Autrement dit, les cereales bien notees par Consumer Reports sont celles riches en fibres et pauvres en calories/sucres. La note reflete donc assez fidelement la "qualite nutritionnelle" telle que definie par les axes de l'ACP.

Pour les fabricants, Nabisco (N) se positionne clairement dans le quadrant "fibres elevees, peu caloriques", ce qui est coherent avec leur gamme Shredded Wheat. General Mills (G) et Kellogg's (K) occupent des positions plus centrales, avec des gammes variees.

Les cereales chaudes (H, 3 seulement) se projettent a l'ecart des froides, mais l'effectif est trop faible pour en tirer des conclusions solides.

5 Classification

5.1 CAH - Methode de Ward




FIGURE 6 – Dendrogramme (CAH, Ward, distance euclidienne)

On applique la CAH avec la distance euclidienne sur les données centrées-réduites et le critère de Ward, qui minimise l'augmentation d'inertie intra-classe à chaque fusion. Ce critère est cohérent avec la métrique euclidienne utilisée, et tend à produire des clusters de taille comparable.

Le dendrogramme suggère une partition en 3 classes, avec un saut d'inertie visible entre 3 et 2 clusters. La silhouette moyenne pour $k=3$ est de 0.21, ce qui est modeste. Pour comparaison, $k=2$ donne une silhouette de 0.45, plus nette, mais on perd l'information sur le groupe des céréales très riches en fibres.



FIGURE 7 – Profils moyens des 3 clusters (CAH, donnees centrees-reduites)

Les trois clusters obtenus sont :

- **Cluster 1** (3 cereales) : profil “haute fibre”. FIBER et POTASS tres eleves, CALORIES et CARBO faibles. Ce sont les trois cereales All-Bran.
- **Cluster 2** (40 cereales) : profil “sucre/calorique”. SUGARS et CALORIES au-dessus de la moyenne, FIBER et CARBO en dessous.
- **Cluster 3** (34 cereales) : profil “modere”. Peu de sucre, peu de gras, CARBO eleve. Ce sont des cereales de type classique (Corn Flakes, Rice Krispies, etc.).

Le cluster 1 ne contient que 3 individus, ce qui le rend fragile. Ce sont en realite des outliers nutritionnels et pas un “type” de cereale au sens commercial du terme. Mais leur separation est nette et reproductible.

5.2 K-means

On applique le K-means avec le meme nombre de clusters ($k=3$) pour comparer. On utilise $nstart=25$ pour attenuer l’effet de l’initialisation aleatoire (l’algorithme est non deterministe, contrairement a la CAH).




FIGURE 8 – Projection des clusters K-means sur le plan ACP

Les clusters K-means sont très similaires à ceux de la CAH. La projection sur le plan ACP montre une bonne séparation : le cluster “haute fibre” est isolé à droite, le cluster “sucre” est en haut et le cluster “modéré” en bas à gauche.

5.3 Comparaison CAH vs K-means




FIGURE 9 – Silhouette des clusters K-means

L'indice de Rand entre les deux partitions est de 0.882, ce qui indique un bon accord. La pureté est de 0.935 : 93.5% des individus sont classés dans le même groupe par les deux méthodes. Les quelques divergences concernent des céréales à la frontière entre les clusters “sucré” et “modéré”, ce qui est attendu puisque cette frontière est moins nette que la séparation avec le groupe haute fibre.




FIGURE 10 – RATING par cluster (K-means)

Le RATING moyen par cluster confirme l'interprétation : les céréales haute fibre (cluster 3) ont un RATING moyen de 73.8, contre 51.4 pour les modérées et 33.3 pour les sucrées. La note Consumer Reports pénalise les céréales sucrées et valorise les céréales riches en fibres, ce qui est cohérent avec les recommandations diététiques actuelles.

6 Conclusion

L'analyse du jeu de données "276 cereales" a permis de mettre en évidence deux axes de variabilité principaux : la teneur en fibres (et potassium associé) d'une part, et la densité calorique (calories, sucres, graisses) d'autre part. Ces deux axes suffisent à expliquer plus de la moitié de la variance totale.

La classification en 3 groupes, obtenue de manière cohérente par CAH et K-means ($\text{Rand} = 0.88$), distingue des céréales "sucrées/caloriques" (le groupe le plus nombreux), des céréales "modérées/classiques", et un petit groupe de céréales très riches en fibres. Ce dernier groupe est composé uniquement de céréales All-Bran et constitue une niche nutritionnelle.

Un résultat à noter : la variable RATING (non utilisée dans la construction des axes) se projette presque parfaitement dans le plan factoriel. Elle est positivement associée aux fibres et négativement aux sucres, ce qui suggère que Consumer Reports évalue la qualité nutritionnelle selon des critères proches de ceux identifiés par l'ACP.

Une limite de cette analyse : la partition en 3 clusters a une silhouette moyenne modeste (0.22), et le groupe haute fibre ne contient que 3 individus. Une partition en 2 clusters serait plus robuste statistiquement, mais moins informative. Le choix de $k=3$ est un compromis entre stabilité et finesse d'interprétation.

7 Annexe : code R

Le code complet est organisé en 6 scripts exécutables séquentiellement via `00_main.R`. Les packages utilisés sont `FactoMineR`, `factoextra`, `corrplot`, `cluster` et `moments`.

Les scripts sont disponibles dans le dossier `scripts/` du projet :

- `01_pretraitement.R` : chargement, gestion des NA, imputation par la médiane
- `02_stats_descriptives.R` : statistiques univariées et bivariées
- `03_acp.R` : ACP normée avec `FactoMineR`
- `04_cah.R` : CAH (Ward, distance euclidienne)
- `05_kmeans.R` : K-means et comparaison avec la CAH
- `06_synthese.R` : projections et interprétation finale