

Projet TDN - Analyse des céréales

Binome 5

2025-2026

Table des matières

1	Introduction	3
2	Description des données	3
2.1	Presentation du jeu de données	3
2.2	Pretraitement	3
2.3	Définition des roles pour l'ACP	3
3	Statistiques descriptives	4
3.1	Analyse univariée	4
3.2	Analyse bivariée	5
4	Analyse en composantes principales	5
4.1	Choix de l'ACP normée	5
4.2	Valeurs propres et nombre d'axes	6
4.3	Cercle des corrélations	7
4.4	Carte des individus et biplot	8
4.5	Variables supplémentaires	8
5	Classification	9
5.1	CAH - Methode de Ward	9
5.2	K-means	10
5.3	Comparaison CAH vs K-means	12
6	Conclusion	13
7	Annexe : code R	14

Table des figures

1	Boxplots des variables actives (centrees-reduites)	4
2	Matrice de correlation des variables actives	5
3	Eboulis des valeurs propres	6
4	Cercle des corrélations (axes 1-2)	7
5	Biplot - individus et variables	8
6	Dendrogramme (CAH, Ward, distance euclidienne)	9
7	Profils moyens des 3 clusters (CAH, donnees centrees-reduites)	10
8	Projection des clusters K-means sur le plan ACP	11
9	Silhouette des clusters K-means	12
10	RATING par cluster (K-means)	12

1 Introduction

Ce rapport présente l'analyse d'un jeu de données portant sur 77 céréales de petit-déjeuner commercialisées aux États-Unis. L'objectif est de comprendre comment ces céréales se différencient sur le plan nutritionnel, et si on peut identifier des groupes homogènes parmi elles.

On dispose de 16 variables par céréale : des informations nutritionnelles (calories, protéines, graisses, etc.), des variables de conditionnement (poids, taille de portion), et des métadonnées (fabricant, type de consommation, note de satisfaction). Les variables sont mesurées dans des unités très différentes (Kcal, grammes, milligrammes, note sur 100), ce qui oriente directement le choix des méthodes.

L'approche retenue combine une ACP normée pour réduire la dimensionnalité et visualiser les relations entre variables, suivie de deux méthodes de classification (CAH et K-means) pour regrouper les céréales en profils nutritionnels distincts.

2 Description des données

2.1 Présentation du jeu de données

Le fichier `276-cereals.txt` contient 77 céréales décrites par 16 variables. Après examen de la structure, on distingue trois types de variables :

- **Identifiant** : NAME (nom de la céréale)
- **Variables qualitatives** : MANUF (fabricant, 7 modalités : A, G, K, N, P, Q, R) et TYPE (C = consommation froide, H = chaude)
- **Variables quantitatives** (13) : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS, VITAMINS, SHELF, WEIGHT, CUPS, RATING

La répartition est déséquilibrée : 74 céréales froides contre seulement 3 chaudes. Les fabricants Kellogg's (K, 23 céréales) et General Mills (G, 22) dominent le jeu de données.

2.2 Pretraitement

Certaines valeurs sont codées -1 dans le fichier original. Après vérification, il s'agit de données manquantes (une valeur négative n'a pas de sens pour des contenus nutritionnels). On a identifié 4 valeurs manquantes : 2 pour POTASS, 1 pour CARBO, 1 pour SUGARS.

On a choisi de les imputer par la médiane de chaque variable. La médiane est plus robuste que la moyenne face aux valeurs extrêmes, ce qui est pertinent ici puisque certaines variables comme FIBER ou POTASS présentent des distributions très asymétriques.

2.3 Définition des rôles pour l'ACP

Pour l'ACP, on a sélectionné 9 variables actives correspondant aux caractéristiques nutritionnelles pures : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS et VITAMINS.

Les variables SHELF, WEIGHT, CUPS et RATING sont traitées comme variables supplémentaires quantitatives : elles ne participent pas à la construction des axes mais sont projetées à posteriori pour enrichir l'interprétation. MANUF et TYPE sont des variables supplémentaires qualitatives.

Ce choix se justifie : WEIGHT et CUPS décrivent le conditionnement, pas la composition nutritionnelle. RATING est une note calculée par Consumer Reports, donc une variable dérivée que l'on préfère analyser en complément afin d'examiner sa position par rapport aux axes nutritionnels.

3 Statistiques descriptives

3.1 Analyse univariée

Le tableau ci-dessous résume les principales statistiques des variables actives :

TABLE 1: Statistiques des variables actives

	Moyenne	Mediane	Ecart.type	Skewness
CALORIES	106.9	110.0	19.5	-0.44
PROTEIN	2.5	3.0	1.1	0.73
FAT	1.0	1.0	1.0	1.14
SODIUM	159.7	180.0	83.8	-0.56
FIBER	2.2	2.0	2.4	2.38
CARBO	14.8	14.5	3.9	0.11
SUGARS	7.0	7.0	4.3	0.04
POTASS	98.4	90.0	69.5	1.40
VITAMINS	28.2	25.0	22.3	2.42

Quelques constats : FIBER (skewness = 2.38) et VITAMINS (2.42) sont très asymétriques à droite, ce qui signifie que la plupart des céréales ont peu de fibres et de vitamines, avec quelques exceptions notables. SUGARS est à peu près symétrique (skewness = 0.04), les céréales se répartissent assez uniformément entre peu et très sucrées.




FIGURE 1 – Boxplots des variables actives (centrees-reduites)

Les boxplots montrent plusieurs outliers, en particulier pour FIBER et POTASS (les céréales All-Bran) et pour VITAMINS (les céréales “Total” enrichies à 100% des apports). On conserve ces observations car elles représentent de vraies céréales du marché, même si elles sont atypiques.

3.2 Analyse bivariée




FIGURE 2 – Matrice de corrélation des variables actives

La matrice de corrélation révèle une structure intéressante. La corrélation la plus forte est entre FIBER et POTASS ($r = 0.91$). Ce lien est logique d'un point de vue nutritionnel : les céréales complètes, riches en fibres, conservent les minéraux du grain, dont le potassium. On note aussi que CALORIES est corrélé positivement à SUGARS ($r = 0.57$) et FAT ($r = 0.50$), ce qui reflète simplement le fait que sucres et graisses sont des sources caloriques.

CARBO est corrélé négativement à SUGARS ($r = -0.47$), ce qui peut sembler contre-intuitif. En fait, les céréales riches en glucides complexes (amidon) sont souvent moins sucrées : les sucres simples remplacent l'amidon, ils ne s'y ajoutent pas.

L'existence de ces corrélations justifie le recours à l'ACP : les 9 variables ne sont pas indépendantes et une réduction de dimension permettra de mieux visualiser cette structure.

4 Analyse en composantes principales

4.1 Choix de l'ACP normée

Les variables étant mesurées dans des unités différentes (Kcal, grammes, milligrammes, note), une ACP non normée donnerait un poids disproportionné aux variables à forte variance comme SODIUM (écart-type = 84) ou POTASS (écart-type = 69) par rapport à FAT (écart-type = 1). L'ACP normée, qui travaille sur la matrice de corrélation après centrage-réduction, traite toutes les variables de manière équitable

4.2 Valeurs propres et nombre d'axes

FIGURE 3 – Eboulis des valeurs propres

Le critère de Kaiser (valeurs propres > 1) conduit à retenir 4 axes, qui captent 82.1% de l'inertie totale. Les deux premiers axes concentrent à eux seuls 52.4% de l'information, ce qui est correct pour 9 variables. Le scree plot ne montre pas de coude très marqué mais une décroissance progressive. On se concentrera sur le plan factoriel (1,2) pour les interprétations principales, en gardant à l'esprit que les axes 3 et 4 portent encore de l'information non négligeable.

4.3 Cercle des corrélations




FIGURE 4 – Cercle des corrélations (axes 1-2)

L'axe 1 (29.4% d'inertie) est principalement construit par FIBER et POTASS du côté positif. C'est un axe qu'on peut interpréter comme un gradient de "richesse en fibres". Les céréales à droite du plan sont riches en fibres et en potassium, celles à gauche en sont pauvres.

L'axe 2 (23.0%) oppose CALORIES, FAT et SUGARS (en haut) à un pôle plus neutre (en bas). C'est un axe de "densité calorique" : les céréales en haut du plan sont plus caloriques, plus grasses et plus sucrées.

On remarque que SODIUM et VITAMINS sont mal représentés sur ce plan (vecteurs courts), ce qui confirme que les axes 3 et 4 capturent l'information de ces variables. CARBO est dans le cadran bas-gauche, opposé à SUGARS : cela confirme l'opposition glucides complexes / sucres simples vue dans les corrélations.

4.4 Carte des individus et biplot




FIGURE 5 – Biplot - individus et variables

Le biplot permet de voir les céréales et les variables en même temps. Les trois céréales All-Bran (100% Bran, All-Bran, All-Bran with Extra Fiber) sont clairement isolées à droite, du côté des fibres. A l'opposé, on trouve Rice Chex, Corn Chex et d'autres céréales à base de riz ou maïs, pauvres en fibres.

En haut du plan, les céréales sucrées (Cap'n Crunch, Froot Loops, Lucky Charms) s'alignent avec les vecteurs SUGARS et CALORIES. En bas, les céréales peu caloriques comme Puffed Rice ou Shredded Wheat.

4.5 Variables supplémentaires

La variable RATING se projette avec une coordonnée positive sur l'axe 1 (+0.62) et négative sur l'axe 2 (-0.72). Autrement dit, les céréales bien notées par Consumer Reports sont celles riches en fibres et pauvres en calories/sucres. La note reflète donc assez fidèlement la "qualité nutritionnelle" telle que définie par les axes de l'ACP.

Pour les fabricants, Nabisco (N) se positionne clairement dans le quadrant "fibres élevées, peu caloriques", ce qui est cohérent avec leur gamme Shredded Wheat. General Mills (G) et Kellogg's (K) occupent des positions plus centrales, avec des gammes variées.

Les céréales chaudes (H, 3 seulement) se projettent à l'écart des froides, mais l'effectif est trop faible pour en tirer des conclusions solides.

5 Classification

5.1 CAH - Methode de Ward

FIGURE 6 – Dendrogramme (CAH, Ward, distance euclidienne)

On applique la CAH avec la distance euclidienne sur les données centrées-réduites et le critère de Ward, qui minimise l'augmentation d'inertie intra-classe à chaque fusion. Ce critère est cohérent avec la métrique euclidienne utilisée et tend à produire des clusters de taille comparable.

Le dendrogramme suggère une partition en 3 classes, avec un saut d'inertie visible entre 3 et 2 clusters. La silhouette moyenne pour $k=3$ est de 0.21, ce qui est modeste. Pour comparaison, $k=2$ donne une silhouette de 0.45, plus nette, mais on perd l'information sur le groupe des céréales très riches en fibres.



FIGURE 7 – Profils moyens des 3 clusters (CAH, données centrées-réduites)

Les trois clusters obtenus sont :

- **Cluster 1** (3 céréales) : profil “haute fibre”. FIBER et POTASS très élevés, CALORIES et CARBO faibles. Ce sont les trois céréales All-Bran.
- **Cluster 2** (40 céréales) : profil “sucre/calorique”. SUGARS et CALORIES au-dessus de la moyenne, FIBER et CARBO en dessous.
- **Cluster 3** (34 céréales) : profil “modéré”. Peu de sucre, peu de gras, CARBO élevé. Ce sont des céréales de type classique (Corn Flakes, Rice Krispies, etc.).

Le cluster 1 ne contient que 3 individus, ce qui le rend fragile. Ce sont en réalité des outliers nutritionnels et pas un “type” de céréale au sens commercial du terme. Mais leur séparation est nette et reproductible.

5.2 K-means

On applique le K-means avec le même nombre de clusters ($k=3$) pour comparer. On utilise $nstart=25$ pour atténuer l’effet de l’initialisation aléatoire (l’algorithme est non déterministe, contrairement à la CAH).




FIGURE 8 – Projection des clusters K-means sur le plan ACP

Les clusters K-means sont très similaires à ceux de la CAH. La projection sur le plan ACP montre une bonne séparation : le cluster “haute fibre” est isolé à droite, le cluster “sucre” est en haut et le cluster “modere” en bas à gauche.

5.3 Comparaison CAH vs K-means




FIGURE 9 – Silhouette des clusters K-means

L'indice de Rand entre les deux partitions est de 0.882, ce qui indique un bon accord. La pureté est de 0.935 : 93.5% des individus sont classés dans le même groupe par les deux méthodes. Les quelques divergences concernent des céréales à la frontière entre les clusters “sucre” et “modere”, ce qui est attendu puisque cette frontière est moins nette que la séparation avec le groupe haute fibre.




FIGURE 10 – RATING par cluster (K-means)

Le RATING moyen par cluster confirme l'interprétation : les céréales haute fibre (cluster 3) ont un RATING moyen de 73.8, contre 51.4 pour les modérées et 33.3 pour les sucrées. La note Consumer Reports pénalise les céréales sucrées et valorise les céréales riches en fibres, ce qui est cohérent avec les recommandations diététiques actuelles.

6 Conclusion

L'analyse du jeu de données “276 céréales” a permis de mettre en évidence deux axes de variabilité principaux : la teneur en fibres (et potassium associé) d'une part, et la densité calorique (calories, sucres, graisses) d'autre part. Ces deux axes suffisent à expliquer plus de la moitié de la variance totale.

La classification en 3 groupes, obtenue de manière cohérente par CAH et K-means ($\text{Rand} = 0.88$), distingue des céréales “sucrées/caloriques” (le groupe le plus nombreux), des céréales “modérées/classiques”, et un petit groupe de céréales très riches en fibres. Ce dernier groupe est composé uniquement de céréales All-Bran et constitue une niche nutritionnelle.

Un résultat à noter : la variable RATING (non utilisée dans la construction des axes) se projette presque parfaitement dans le plan factoriel. Elle est positivement associée aux fibres et négativement aux sucres, ce qui suggère que Consumer Reports évalue la qualité nutritionnelle selon des critères proches de ceux identifiés par l'ACP.

Une limite de cette analyse : la partition en 3 clusters a une silhouette moyenne modeste (0.22), et le groupe haute fibre ne contient que 3 individus. Une partition en 2 clusters serait plus robuste statistiquement, mais moins informative. Le choix de $k=3$ est un compromis entre stabilité et finesse d'interprétation.

7 Annexe : code R

Le code complet est organisé en 6 scripts exécutables séquentiellement via `00_main.R`. Les packages utilisés sont `FactoMineR`, `factoextra`, `corrplot`, `cluster` et `moments`.

Les scripts sont disponibles dans le dossier `scripts/` du projet :

- `01_pretraitement.R` : chargement, gestion des NA, imputation par la médiane
- `02_stats_descriptives.R` : statistiques univariées et bivariées
- `03_acp.R` : ACP normée avec `FactoMineR`
- `04_cah.R` : CAH (Ward, distance euclidienne)
- `05_kmeans.R` : K-means et comparaison avec la CAH
- `06_synthese.R` : projections et interprétation finale