

Projet TND - Analyse des céréales

Trinome 5

2025-2026

Table des matières

1	Introduction	2
2	Description des données	2
2.1	Présentation du jeu de données	2
2.2	Prétraitement	2
2.3	Définition des rôles pour l'ACP	2
3	Statistiques descriptives	3
3.1	Analyse univariée	3
3.2	Analyse bivariée	4
4	Analyse en composantes principales	4
4.1	Choix de l'ACP normée	4
4.2	Valeurs propres et nombre d'axes	5
4.3	Cercle des corrélations	6
4.4	Carte des individus et biplot	7
4.5	Variables supplémentaires	7
5	Classification	8
5.1	CAH - Méthode de Ward	8
5.2	K-means	9
5.3	Comparaison CAH vs K-means	10
6	Conclusion	10
7	Annexe : code R	11

Table des figures

1	Boxplots des variables actives (centrées-réduites)	3
2	Matrice de corrélation des variables actives	4
3	Éboulis des valeurs propres	5
4	Cercle des corrélations (axes 1-2)	6
5	Biplot - individus et variables	7
6	Dendrogramme (CAH, Ward, distance euclidienne)	8
7	Profils moyens des 3 clusters (CAH, données centrées-réduites)	8
8	Projection des clusters K-means sur le plan ACP	9
9	Silhouette des clusters K-means	10
10	RATING par cluster (K-means)	10

1 Introduction

Ce rapport porte sur 77 céréales de petit-déjeuner vendues aux États-Unis. On cherche à voir comment elles se distinguent sur le plan nutritionnel, et s'il existe des groupes de céréales qui se ressemblent.

Chaque céréale est décrite par 16 variables : des données nutritionnelles (calories, protéines, graisses, etc.), des informations de conditionnement (poids, taille de portion) et quelques métadonnées (fabricant, type de consommation, note de satisfaction). Les unités sont très hétérogènes : des Kcal, des grammes, des milligrammes, une note sur 100. C'est ce qui nous a poussés vers une ACP normée plutôt qu'une ACP classique.

On a donc commencé par une ACP normée pour résumer l'information et regarder comment les variables sont reliées, puis on a appliqué deux méthodes de classification, la CAH et les K-means, pour voir si des profils nutritionnels se dégagent.

2 Description des données

2.1 Présentation du jeu de données

Le fichier `276-cereals.txt` contient 77 céréales et 16 variables. En regardant la structure, on retrouve trois types de variables :

- **Identifiant** : NAME (nom de la céréale)
- **Variables qualitatives** : MANUF (fabricant, 7 modalités : A, G, K, N, P, Q, R) et TYPE (C = consommation froide, H = chaude)
- **Variables quantitatives** (13) : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS, VITAMINS, SHELF, WEIGHT, CUPS, RATING

La répartition est déséquilibrée : 74 céréales froides pour seulement 3 chaudes. Côté fabricants, Kellogg's (K, 23 céréales) et General Mills (G, 22) représentent à eux deux plus de la moitié du jeu de données.

2.2 Prétraitement

Certaines valeurs valent -1 dans le fichier d'origine. Une valeur négative n'ayant aucun sens pour un contenu nutritionnel, on les a traitées comme des données manquantes. Il y en a 4 au total : 2 sur POTASS, 1 sur CARBO, 1 sur SUGARS.

On les a remplacées par la médiane de chaque variable. La médiane résiste mieux que la moyenne aux valeurs extrêmes, ce qui compte ici parce que des variables comme FIBER ou POTASS ont des distributions très étalées.

2.3 Définition des rôles pour l'ACP

Pour l'ACP, on a gardé 9 variables actives, celles qui décrivent vraiment la composition nutritionnelle : CALORIES, PROTEIN, FAT, SODIUM, FIBER, CARBO, SUGARS, POTASS et VITAMINS.

SHELF, WEIGHT, CUPS et RATING passent en variables supplémentaires quantitatives : elles n'entrent pas dans le calcul des axes mais on les projette ensuite pour aider à l'interprétation. MANUF et TYPE sont des variables supplémentaires qualitatives.

Ce découpage se justifie facilement : WEIGHT et CUPS parlent du conditionnement, pas du contenu. RATING est une note calculée par Consumer Reports ; comme c'est une variable construite à partir des autres, on préfère la regarder à part pour voir où elle tombe par rapport aux axes nutritionnels.

3 Statistiques descriptives

3.1 Analyse univariée

Le tableau ci-dessous reprend les principales statistiques des variables actives :

TABLE 1: Statistiques des variables actives

	Moyenne	Médiane	Écart-type	Skewness
CALORIES	106.9	110.0	19.5	-0.44
PROTEIN	2.5	3.0	1.1	0.73
FAT	1.0	1.0	1.0	1.14
SODIUM	159.7	180.0	83.8	-0.56
FIBER	2.2	2.0	2.4	2.38
CARBO	14.8	14.5	3.9	0.11
SUGARS	7.0	7.0	4.3	0.04
POTASS	98.4	90.0	69.5	1.40
VITAMINS	28.2	25.0	22.3	2.42

Deux ou trois choses ressortent. FIBER (skewness = 2.38) et VITAMINS (2.42) sont fortement étalées vers la droite : la plupart des céréales en contiennent peu, sauf quelques cas extrêmes. SUGARS, au contraire, est presque symétrique (skewness = 0.04) ; les céréales se répartissent à peu près également entre peu et très sucrées.




FIGURE 1 – Boxplots des variables actives (centrées-réduites)

Les boxplots font apparaître plusieurs valeurs atypiques, surtout sur FIBER et POTASS (les All-Bran) et sur VITAMINS (les “Total” enrichies à 100% des apports). On a choisi de les garder : ce sont de vraies céréales du marché, même si elles sortent du lot.

3.2 Analyse bivariée




FIGURE 2 – Matrice de corrélation des variables actives

La matrice de corrélation est plutôt parlante. La corrélation la plus forte relie FIBER et POTASS ($r = 0.91$), ce qui se comprend bien : les céréales complètes, riches en fibres, gardent les minéraux du grain, dont le potassium. CALORIES est aussi corrélé à SUGARS ($r = 0.57$) et à FAT ($r = 0.50$) : sans surprise, sucres et graisses apportent des calories.

CARBO est corrélé négativement à SUGARS ($r = -0.47$). Ça paraît étrange au premier abord, mais en pratique les céréales riches en glucides complexes (amidon) sont souvent peu sucrées : le sucre remplace l'amidon au lieu de s'y ajouter.

Ces corrélations expliquent pourquoi une ACP a du sens ici : les 9 variables sont loin d'être indépendantes, et réduire la dimension permet de mieux voir leur structure.

4 Analyse en composantes principales

4.1 Choix de l'ACP normée

Comme les variables sont dans des unités différentes (Kcal, grammes, milligrammes, note), une ACP non normée donnerait beaucoup trop de poids aux variables à forte variance comme SODIUM (écart-type = 84) ou POTASS (écart-type = 69) face à FAT (écart-type = 1). L'ACP normée travaille sur la matrice de corrélation, après centrage-réduction, et met donc toutes les variables sur un pied d'égalité.

4.2 Valeurs propres et nombre d'axes




FIGURE 3 – Éboulis des valeurs propres

Le critère de Kaiser (valeurs propres > 1) retient 4 axes, qui couvrent 82.1% de l'inertie. Les deux premiers en cumulent déjà 52.4%, ce qui reste correct pour 9 variables. Le scree plot ne montre pas de coude franc, plutôt une décroissance régulière. On fera l'essentiel des interprétations sur le plan (1,2), en gardant en tête que les axes 3 et 4 portent encore une part non négligeable de l'information.

4.3 Cercle des corrélations




FIGURE 4 – Cercle des corrélations (axes 1-2)

L'axe 1 (29.4% d'inertie) est surtout tiré par FIBER et POTASS du côté positif. On peut le lire comme un gradient de richesse en fibres : à droite les céréales riches en fibres et en potassium, à gauche celles qui en sont pauvres.

L'axe 2 (23.0%) oppose CALORIES, FAT et SUGARS (en haut) à un pôle plus neutre (en bas). C'est l'axe de la densité calorique : en haut, les céréales les plus caloriques, les plus grasses et les plus sucrées.

SODIUM et VITAMINS sont mal représentés sur ce plan (vecteurs courts), ce qui confirme qu'ils sont surtout portés par les axes 3 et 4. CARBO se retrouve dans le cadran bas-gauche, à l'opposé de SUGARS : on retrouve l'opposition glucides complexes / sucres simples déjà vue dans les corrélations.

4.4 Carte des individus et biplot




FIGURE 5 – Biplot - individus et variables

Le biplot permet de regarder céréales et variables en même temps. Les trois All-Bran (100% Bran, All-Bran, All-Bran with Extra Fiber) se détachent nettement à droite, du côté des fibres. À l'opposé, on trouve Rice Chex, Corn Chex et les autres céréales à base de riz ou de maïs, pauvres en fibres.

En haut, les céréales sucrées (Cap'n'Crunch, Froot Loops, Lucky Charms) suivent les vecteurs SUGARS et CALORIES. En bas, les céréales peu caloriques type Puffed Rice ou Shredded Wheat.

4.5 Variables supplémentaires

RATING se projette avec une coordonnée positive sur l'axe 1 (+0.62) et négative sur l'axe 2 (-0.72). Autrement dit, les céréales bien notées par Consumer Reports sont riches en fibres et pauvres en calories et en sucres. La note suit donc d'assez près la qualité nutritionnelle telle que la décrivent les axes de l'ACP.

Pour les fabricants, Nabisco (N) se place clairement dans le coin fibres élevées / peu calorique, ce qui colle avec sa gamme Shredded Wheat. General Mills (G) et Kellogg's (K) restent plus au centre, avec des gammes variées. Les 3 céréales chaudes (H) se projettent à part des froides, mais elles sont trop peu nombreuses pour en conclure quoi que ce soit.

5 Classification

5.1 CAH - Méthode de Ward




FIGURE 6 – Dendrogramme (CAH, Ward, distance euclidienne)

On lance la CAH avec la distance euclidienne sur les données centrées-réduites et le critère de Ward, qui minimise la hausse d'inertie intra-classe à chaque fusion. Ce critère va bien avec la distance euclidienne et donne en général des classes de tailles proches.

Le dendrogramme penche pour une partition en 3 classes, avec un saut d'inertie net entre 3 et 2 clusters. La silhouette moyenne à $k=3$ vaut 0.21, ce qui est faible. À $k=2$ elle monte à 0.45, donc plus propre, mais on perd alors le groupe des céréales très riches en fibres, qui nous intéresse.




FIGURE 7 – Profils moyens des 3 clusters (CAH, données centrées-réduites)

Les trois clusters obtenus sont :

- **Cluster 1** (3 céréales) : profil “haute fibre”. FIBER et POTASS très élevés, CALORIES et CARBO faibles. Ce sont les trois céréales All-Bran.
- **Cluster 2** (40 céréales) : profil “sucre/calorique”. SUGARS et CALORIES au-dessus de la moyenne, FIBER et CARBO en dessous.
- **Cluster 3** (34 céréales) : profil “modéré”. Peu de sucre, peu de gras, CARBO élevé. Ce sont des céréales de type classique (Corn Flakes, Rice Krispies, etc.).

Le cluster 1 ne compte que 3 individus, ce qui le rend fragile. Ce sont en réalité des outliers nutritionnels plus qu’un vrai “type” commercial de céréale. Cela dit, leur séparation est franche et reproductible.

5.2 K-means

On refait une classification en K-means avec le même $k=3$ pour comparer. On met $nstart=25$ pour limiter l’effet du tirage initial, l’algorithme n’étant pas déterministe contrairement à la CAH.




FIGURE 8 – Projection des clusters K-means sur le plan ACP

Les clusters K-means ressemblent beaucoup à ceux de la CAH. Sur le plan ACP, la séparation est nette : le groupe “haute fibre” est isolé à droite, le groupe “sucre” en haut et le groupe “modéré” en bas à gauche.

5.3 Comparaison CAH vs K-means




FIGURE 9 – Silhouette des clusters K-means

L'indice de Rand entre les deux partitions vaut 0.882, donc un bon accord. La pureté est de 0.935 : 93.5% des céréales tombent dans le même groupe selon les deux méthodes. Les rares désaccords concernent des céréales à la limite entre les groupes “sucre” et “modéré”, ce qui n'a rien d'étonnant puisque cette frontière est moins marquée que la séparation avec le groupe haute fibre.




FIGURE 10 – RATING par cluster (K-means)

Le RATING moyen par cluster va dans le même sens : 73.8 pour les céréales haute fibre, 51.4 pour les modérées et 33.3 pour les sucrées. La note de Consumer Reports pénalise le sucre et valorise les fibres, ce qui correspond aux recommandations diététiques actuelles.

6 Conclusion

L'analyse du jeu “276 céréales” fait ressortir deux grands axes de variation : d'un côté la teneur en fibres (et le potassium qui va avec), de l'autre la densité calorique (calories, sucres, graisses). À eux deux, ils expliquent plus de la moitié de la variance totale.

La classification en 3 groupes, retrouvée de façon cohérente par la CAH et les K-means (Rand = 0.88), sépare un gros groupe de céréales “sucrées/caloriques”, un groupe de céréales “modérées/classiques”, et un petit groupe très riche en fibres composé uniquement d’All-Bran.

Un point qui nous a marqués : RATING, qui n’entre pas dans le calcul des axes, se projette presque parfaitement dans le plan factoriel. Elle est liée positivement aux fibres et négativement aux sucres, ce qui laisse penser que Consumer Reports juge la qualité nutritionnelle avec des critères proches de ceux que sort l’ACP.

Il reste une limite : la partition en 3 clusters a une silhouette moyenne faible (0.22) et le groupe haute fibre ne contient que 3 individus. Une partition en 2 clusters serait plus solide statistiquement mais moins informative. Le choix de k=3 est un compromis entre stabilité et finesse d’interprétation.

7 Annexe : code R

Toute l’analyse tient dans un seul script, `scripts/analyse_cereales.R`, qui enchaîne le prétraitement, les statistiques descriptives, l’ACP normée, la CAH, les K-means et la synthèse. Il s’appuie sur les packages FactoMineR, factoextra, corrplot, cluster et moments.

```
# Projet TND - Analyse des cereales
# ACP normee + CAH + K-means sur les 77 cereales de 276-cereals.txt
library(FactoMineR); library(factoextra); library(corrplot)
library(cluster); library(moments)
set.seed(42)

# --- Pretraitement -----
cereales <- read.table("Binome5/276-cereals.txt", header = TRUE, sep = "\t",
                      strip.white = TRUE, quote = "", comment.char = "")
quanti <- c("CALORIES", "PROTEIN", "FAT", "SODIUM", "FIBER", "CARBO", "SUGARS",
           "POTASS", "VITAMINS", "SHELF", "WEIGHT", "CUPS", "RATING")
for (c in quanti) {
  cereales[[c]][cereales[[c]] == -1] <- NA
  cereales[[c]][is.na(cereales[[c]])] <- median(cereales[[c]], na.rm = TRUE)
}
cereales$MANUF <- factor(cereales$MANUF); cereales$TYPE <- factor(cereales$TYPE)
rownames(cereales) <- make.unique(trimws(cereales$NAME))
actives <- c("CALORIES", "PROTEIN", "FAT", "SODIUM", "FIBER", "CARBO",
            "SUGARS", "POTASS", "VITAMINS")

# --- Statistiques descriptives -----
print(round(data.frame(
  Moy = sapply(cereales[actives], mean), Med = sapply(cereales[actives], median),
  Sd = sapply(cereales[actives], sd), Skew = sapply(cereales[actives], skewness)), 2))
X <- scale(cereales[actives])
print(round(cor(cereales[actives]), 2))
corrplot(cor(cereales[actives]), method = "color", type = "upper",
         order = "hclust", addCoef.col = "black", tl.col = "black")

# --- ACP normee (variables suppl. : conditionnement, RATING, MANUF, TYPE) ---
acp <- PCA(cereales[, c(actives, "SHELF", "WEIGHT", "CUPS", "RATING", "MANUF", "TYPE")],
          quanti.sup = 10:13, quali.sup = 14:15,
          scale.unit = TRUE, graph = FALSE)
print(round(acp$eig, 2))
print(round(acp$quanti.sup$coord[, 1:2], 2)) # projection de RATING
fviz_pca_var(acp, col.var = "contrib", repel = TRUE)
fviz_pca_biplot(acp, repel = TRUE, labelsiz = 2)

# --- CAH (Ward, distance euclidienne) -----
hc <- hclust(dist(X), method = "ward.D2")
for (k in 2:6)
  cat("k =", k, ": silhouette =",
      round(mean(silhouette(cutree(hc, k), dist(X))[, 3]), 3), "\n")
cereales$cah <- factor(cutree(hc, 3))
fviz_dend(hc, k = 3, rect = TRUE)

# --- K-means (k = 3, identique a la CAH) -----
```

```

km <- kmeans(X, centers = 3, nstart = 25)
cereales$km <- factor(km$cluster)
prof <- aggregate(X, list(cereales$km), mean); rownames(prof) <- prof[, 1]
barplot(as.matrix(prof[, -1]), beside = TRUE, las = 2,
        col = c("steelblue", "coral", "forestgreen"))

# --- Comparaison des deux partitions -----
print(table(CAH = cereales$cah, Kmeans = cereales$km))
rand <- function(a, b) {
  # indice de Rand
  n <- length(a); s <- 0
  for (i in 1:(n-1)) for (j in (i+1):n)
    s <- s + ((a[i]==a[j]) == (b[i]==b[j]))
  s / choose(n, 2)
}
purete <- function(cl, ref)
  sum(tapply(ref, cl, function(x) max(table(x)))) / length(cl)
ca <- as.integer(cereales$cah); ke <- as.integer(cereales$km)
cat("Rand   :", round(rand(ca, ke), 3), "\n")
cat("Purete :", round(purete(ca, ke), 3), "\n")

# --- Synthese : clusters dans le plan ACP et lien avec RATING -----
fviz_pca_ind(acp, habillage = cereales$km, addEllipses = TRUE,
             repel = TRUE, labelsize = 2)
print(round(tapply(cereales$RATING, cereales$km, mean), 1))
boxplot(RATING ~ km, data = cereales, col = c("steelblue", "coral", "forestgreen"))

```